Almacenamiento y Gestión de la Información

Máster en Ingeniería Informática

[Curso 24-25]

Proyecto de la Asignatura (Primera Parte – MongoDB)

OBJETIVOS

- Llevar a la práctica los conocimientos adquiridos durante el desarrollo de la asignatura
- Evaluar el rendimiento de consultas y optimizarlas
- Diseñar una aplicación que implemente operaciones CRUD sobre una base de datos NoSQL usando MongoDB

Sois los encargados de diseñar las operaciones CRUD de una aplicación que una determinada empresa desea poner en producción para que los usuarios interactúen con su información. Al tener un gran volumen de datos, **vuestra responsabilidad es que las operaciones sean eficientes**, reduciendo al máximo el tiempo de respuesta. El proyecto consiste, por tanto, en la implementación de una aplicación (escritorio, web, etc.) cuya funcionalidad esté basada en la gestión de la información almacenada en un sistema de bases de datos MongoDB.

La base de datos utilizada será la proporcionada por Yelp (https://www.yelp.com/dataset). Según definen sus autores: "*La base de datos de Yelp es un subconjunto de negocios, reseñas y datos de usuarios para usos académicos. Está disponible en formato JSON y es apropiado para enseñar a los estudiantes sobre bases de datos no relacionales, aprender Procesamiento del Lenguaje Natural o como datos de producción de muestra para aplicaciones móviles*".

Esta base de datos contiene 6 ficheros JSON (https://www.yelp.com/dataset/documentation/main). Para este proyecto usaremos los 5 ficheros de texto y no haremos uso de las imágenes (photo.json).

Se descarga un fichero comprimido con el siguiente contenido:

- yelp_academic_dataset_business.json (150346 documentos)
- yelp_academic_dataset_checkin.json (131930 documentos)
- yelp_academic_dataset_review.json (6990280 documentos)
- yelp_academic_dataset_tip.json (908915 documentos)
- yelp_academic_dataset_user.json (1987897 documentos)
- Dataset_User_Agreement.pdf

IMPORTANTE. Para poder corregir el proyecto, la base de datos se debe llamar **yelp** y las colecciones **business**, **checkin**, **review**, **tip** y **user**

He detectado 4 errores en las colecciones respecto a la documentación:

1. El campo "categories" de la colección "business" debería ser un array. Sin embargo, viene como una cadena de elementos separados por coma
2. El campo "attributes" de la colección "business" debería ser un documento incrustado. Sin embargo, está entre comillas y, por tanto, lo trata como una cadena
3. El campo "friends" de la colección "user" debería ser un array. Sin embargo, viene como una cadena de elementos separados por coma
4. El campo "elite" de la colección "user" debería ser un array. Sin embargo, viene como una cadena de elementos separados por coma

Se valorará de forma muy positiva la conversión de estos 4 tipos de datos erróneos a sus tipos correctos

¿Qué hay que hacer?

- Cargar los datos en una base de datos local con 5 colecciones (una por cada fichero). Con la herramienta *import* de *Compass* funciona correctamente

- Proponer **8 operaciones** CRUD para darle funcionalidad a la aplicación. **Se valorará la complejidad y la parametrización de las operaciones**

- Implementar una aplicación mediante algún lenguaje de programación de libre elección (Python, Java, etc.), con una **interfaz gráfica** para ejecutar las operaciones y mostrar los resultados. El objetivo de este proyecto es gestionar eficientemente un gran volumen de información. Por tanto, no os pido que implementéis una aplicación gráfica espectacular, simplemente que sea funcional a la hora de ejecutar las operaciones y mostrar los resultados

A modo de ejemplo, estas pueden ser algunas de las consultas:

  - Número de opiniones (*review*) que ha recibido un negocio
  - Mostrar los usuarios ordenados de mayor a menor número de críticas realizadas
  - Mostrar el nombre de los amigos de un usuario
  - Mostrar el nombre del negocio que ha recibido críticas de un usuario (dado su nombre)

- **Acciones obligatorias**
  - Creación de índices (al menos uno de texto)
  - Dos consultas sobre el campo *text* de la colección *review.json*
  - Dos consultas usando el *Framework Aggregation*
  - Dos consultas que impliquen 2 o más colecciones relacionadas por "referencia"

¿Qué hay que entregar?

- El código y las instrucciones para desplegar la interfaz gráfica y poder trabajar con una base de datos llamada **yelp** ubicada en la IP local (127.0.0.1) y en el puerto 27017

- Una memoria con el siguiente contenido:
  - Código y explicación de las operaciones CRUD propuestas
  - Análisis del rendimiento de **tres de las consultas propuestas**. Analizar su rendimiento "original" y proponer varias estrategias (reformulación del código de la consulta, creación de índices generales y/o parciales, patrones de almacenamiento y acceso a los datos, etc.) para su optimización, justificando la elección de dichas estrategias. Este análisis se realizará con anterioridad, y la elección de **la mejor estrategia** será la que se implemente en la aplicación. **Se pretende comprobar que habéis adquirido capacidades para saber diseñar consultas eficientes**
  - Opinión personal sobre esta parte de la asignatura en general, y del proyecto en particular, aportando propuestas de mejora